

2. The Brake Pedal Is Wired to the Accelerator

[illegible]

3. The Asymmetry of Accountability

4. The Rigged Ledger of Progress

[illegible][illegible][illegible][illegible][illegible]

7. Rhetorical Debugging: From Diagnosis to Procedure

[illegible][illegible]

$$\theta(c, -) > \theta(c, +),$$

[illegible]

$$\mathcal{A}(c) = \theta(c, -) - \theta(c, +)$$

[illegible]

המחוקקים, עתה נשאל: האם יש להחיל את חוקי המס הכנסה על הכנסות אלו? יש להבחין בין שני מקרים: 1. מקרה של הכנסה שנגזרת ישירות מהמסחר, כגון רווחי המסחר. 2. מקרה של הכנסה שנגזרת מהעסקאות, כגון רווחי המסחר. במקרה הראשון, יש להחיל את חוקי המס הכנסה. במקרה השני, יש להחיל את חוקי המס הכנסה.

7.1 The Evidentiary Ledger

[illegible][illegible][illegible][illegible]

7.2 Semantic Dilution as Requirement Shedding

[illegible][illegible][illegible][illegible]

7.3 The Personification Pivot

[illegible][illegible][illegible][illegible]

7.4 Institutional Theater and the Counterfactual Brake

[illegible]

Human in the Loop

[illegible]

$$L = \lambda \tau.$$

[illegible]

Deterrence

[illegible][illegible][illegible]

Emergence and Hallucination

[illegible][illegible]

Feedback

[illegible]

Benchmark

[illegible][illegible]

AGI Forecast

[illegible]

Summary

[illegible]

Maintenance

[illegible]

10. Capability, Contamination, and the Human Baseline

[illegible][illegible]

הוא יוכלו להשתמש בהם כדי להשיג את המטרות שלהם, וזוהי הסיבה לכך שהם נחשבים כמסוכנים. לכן, יש להיזהר מאוד מהם, ולהימנע מהם ככל הניתן.

[illegible]

11. The User as an Extractive Interface

[illegible][illegible][illegible]

12. Limit Cases: When the Record Replaces the World

[illegible][illegible][illegible][illegible][illegible]

A. A Formal Model of Rhetorical Asymmetry

$c = (p, e, a, t, m)$,
 ענחאזאכֶּה :תאזאלעסער ידו t , האטגעצאלירדיג אז וועלעסות עכט־ארב זיך אונדז אן a , דאמאלשצי וואנדערעטלאזט ידו e , זעלנדיאלאקאל ידו אז p טאט־א
 דאס. טאזענדליעסער האטגעצולדיגט ידו m .

[illegible]

13

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

A.1 The Valence-Reversal Operator

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

$$R : (p, e, a, t, m, +1) \mapsto (p', e', a', t', m', -1),$$

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

$$E(e') = E(e), \quad T(t') = T(t), \quad M(m') = M(m), \quad U(Rc) = U(c).$$

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

$$D(c) = D(Rc),$$

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

$$\widehat{\mathcal{I}} = \frac{1}{N} \sum_{i=1}^N |D(c_i) - D(Rc_i)|.$$

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

B. Agency Conservation and the Personification Pivot

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

$$P(A = a \mid o)$$

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

$$\mathbb{P}(o) = (P(A = a_1 \mid o), \dots, P(A = a_k \mid o)).$$

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

$$\Delta_A = d(\mathbb{P}(o^+), \mathbb{P}(o^-)),$$

המטרה היא לתת דוגמה של פונקציה f שהיא רציפה אך לא מתאמת, כלומר f איננה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה. הפונקציה f היא רציפה, כלומר f היא פונקציה רציפה.

$$d_{\neq}(P, Q) = \frac{1}{2} \sum_{a \in \mathcal{G}} |P(a) - Q(a)|.$$

$$\frac{\partial U}{\partial B} \leq 0:$$
[illegible]

$$\frac{\partial U}{\partial B} > 0.$$

אנחנו מניחים כי (p_i, T_i, y_i) היא נקודה שבה T_i היא הטמפרטורה של הנוזל, p_i היא הלחץ, ו- y_i היא המסה של הנוזל.

$$L_n = \sum_{i=1}^n (p_i - y_i)^2$$

$$\mathfrak{W}^\pm(\Delta L_n, \Delta U_n) > 0$$
[illegible]

D. Human Oversight as a Queueing Problem

A

 $\tau.$
$$\mu = \frac{1}{\tau}.$$
$$\rho = \frac{\lambda}{c\mu} = \frac{\lambda\tau}{c}.$$
$$\rho < 1.$$

13

$$P(u_t = \bar{u}_t \mid z_t = z^*) > P(u_t = \bar{u}_t \mid z_t = z_0),$$

אז, z_0 טאגט אן אן אונטערשייד צווישן די צוויי פונקציעס.

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

$$P(u_t = \bar{u}_t \mid z_t = z^*, E = \text{אונטערשייד}) > 0,$$

אזוי, $E = \text{אונטערשייד}$ איז אן אונטערשייד צווישן די צוויי פונקציעס.

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

$$\mathcal{B} = \mathbb{E}_z [P(u = \bar{u} \mid z, E = \text{אונטערשייד}) - P(u = \bar{u} \mid z_0, E = \text{אונטערשייד})].$$

אזוי,

$$\mathcal{B} = 0,$$

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

$$D = P(t + 1 \mid z_t = z^*).$$

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

F. Semantic Dilution as Requirement Loss

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

$$\mathcal{R}_0(w) = \{r_1, r_2, \dots, r_n\}$$

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

$$\mathcal{R}_t(w) \subseteq \mathcal{R}_0(w)$$

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

$$Q_t(w) = \frac{|\mathcal{R}_t(w)|}{|\mathcal{R}_0(w)|}.$$

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

$$Q_t(w) < 1,$$

אזוי, אונזער פונקציעס זענען נישט גלויבליך אונטער די אונטערשייד.

- [illegible]

[illegible]